

Rapport de projet – Deep Learning

Classification de la présence d'épines à l'aide de
CrossViT et analyse de l'attention

Cours : Deep Learning

Année universitaire : 2025 – 2026

Zhao Wangjiachen

Liu Haoxin

Andy NONO KAKEU

Code source (GitHub) :

https://github.com/z992907759/Deep_Learning_projet

Résumé

Ce projet porte sur la classification binaire de la présence d'épines sur des images botaniques, en combinant des images RGB non segmentées et des images segmentées à l'aide d'architectures de type Vision Transformer. Une attention particulière est portée à l'interprétabilité des modèles, via l'analyse des cartes d'attention et leur alignement spatial avec les régions pertinentes de l'image. Plusieurs variantes de modèles sont étudiées (O1 à O5), incluant des stratégies de fusion multi-branches, de pondération des patches et l'intégration d'une régularisation basée sur l'Intersection over Union (IoU).

1. Introduction

L'identification automatique de caractéristiques morphologiques spécifiques dans les images de plantes constitue un problème important en vision par ordinateur. Dans ce contexte, la simple performance de classification ne suffit pas : il est également essentiel de comprendre quelles régions de l'image influencent la décision du modèle.

Les architectures basées sur les Transformers, et plus particulièrement les Vision Transformers (ViT), offrent des mécanismes d'attention permettant d'analyser les contributions spatiales des différentes régions de l'image. Ce projet explore l'utilisation d'une architecture CrossViT à deux branches afin de combiner l'information issue des images non segmentées et des images segmentées.

Les objectifs du projet sont organisés en cinq étapes (O1 à O5), allant de l'étude de configurations de base jusqu'à l'intégration d'une perte tenant compte explicitement de l'alignement spatial entre l'attention du modèle et la plante.

2. Données et protocole expérimental

2.1 Jeu de données

Le jeu de données fourni est composé de paires d'images alignées représentant le même spécimen végétal :

une image RGB non segmentée (raw) ;

une image segmentée (seg), où les pixels correspondant à la plante sont distingués de l'arrière-plan.

Chaque paire est associée à une étiquette binaire indiquant la présence (1) ou l'absence (0) d'épines.



2.2 Division des données et reproductibilité

Les données sont divisées en ensembles d'entraînement et de validation selon un ratio 80 % / 20 %. Une graine aléatoire fixe, définie dans le fichier de configuration du projet, est utilisée pour l'ensemble des expériences afin de garantir la reproductibilité des résultats.

2.3 Métriques d'évaluation

Les performances sont évaluées à l'aide des métriques suivantes :

- Accuracy ;
- F1-score ;
- matrice de confusion ;
- Intersection over Union (IoU) pour l'analyse spatiale de l'attention.

3. Architecture générale : CrossViT

Le modèle de base repose sur une architecture CrossViT à deux branches. Chaque branche est constituée d'un Vision Transformer traitant une modalité différente :

- branche raw : image non segmentée ;
- branche seg : image segmentée.

Les représentations extraites sont fusionnées via un mécanisme de cross-attention avant d'être transmises à une tête de classification.

4. Objectif O1 – Étude des configurations de référence

4.1 Configurations étudiées



Quatre configurations sont évaluées :

- **O1_A** : uniquement images non segmentées ;
- **O1_B** : uniquement images segmentées ;
- **O1_C1** : branche seg avec ViT large et branche raw avec ViT small ;
- **O1_C2** : configuration inverse de O1_C1.

Toutes les configurations utilisent les mêmes hyperparamètres afin d'assurer une comparaison équitable.

4.2 Résultats

Sur O1 (A/B/C1/C2), les performances de classification restent proches (best val_acc $\approx$ 0.522, best val_f1 $\approx$ 0.686), mais l'interprétabilité varie fortement : IoU mean = 0.257 (O1_A), 0.230 (O1_B), 0.580 (O1_C1) et 0.006 (O1_C2). La configuration O1_C1 est la meilleure pour l'alignement spatial.




5. Objectif O2 – Double branche à résolution identique

5.1 Motivation

L'objectif O2 vise à étudier une architecture dans laquelle les deux branches utilisent la même taille de patch et le même nombre de tokens, tout en conservant des poids non partagés.

5.2 Résultats

Le modèle O2 améliore clairement la classification par rapport à O1 (best val_acc = 0.744, best val_f1 = 0.770) avec une IoU mean de 0.461, ce qui confirme l'intérêt d'une fusion cross-attention à résolution identique.



6. Objectif O3 – Pondération des patches basée sur la segmentation

6.1 Méthode


Pour chaque patch issu de l'image segmentée, on calcule le ratio :

$$r_p = (\text{nombre de pixels de plante}) / (\text{nombre total de pixels du patch})$$

Une fonction de pondération croissante $f(r_p)$ est utilisée afin de privilégier les patches contenant une proportion élevée de plante. Les poids sont ensuite propagés vers les patches correspondants de la branche raw, en conservant un alignement spatial strict.

6.2 Résultats

Avec la pondération par patch (O3), on obtient la meilleure classification du projet (best val_acc = 0.789, best val_f1 = 0.800), avec une IoU mean de 0.269. La pondération aide surtout la décision de classification.



7. Objectif O4 – Interprétabilité et métrique IoU


7.1 Attention rollout et visualisation

Les cartes d'attention sont obtenues à l'aide de la méthode d'attention rollout, puis interpolées à la taille de l'image et superposées à celle-ci afin de produire des heatmaps interprétables.



7.2 Évaluation par IoU

Les cartes d'attention sont binarisées avec un seuil au quantile 0,8 puis comparées au masque plante. Les résultats IoU (mean $\pm$ std) sont : O1_A 0.257 $\pm$ 0.154, O1_B 0.230 $\pm$ 0.066, O1_C1 0.580 $\pm$ 0.106, O1_C2 0.006 $\pm$ 0.019, O2 0.461 $\pm$ 0.092, O3 0.269 $\pm$ 0.120, O5 0.325 $\pm$ 0.196.



8. Objectif O5 – Intégration d’une perte basée sur l’IoU


8.1 Formulation de la perte

Le modèle O2 est réentraîné en ajoutant un terme de régularisation basé sur l’IoU à la fonction de perte de classification :

$$L = L_{\text{classification}} + \lambda \cdot (1 - \text{IoU})$$

8.2 Résultats

L’ajout du terme IoU (O5) améliore la cohérence spatiale de l’attention par rapport à O3 (IoU 0.325 vs 0.269), mais n’améliore pas la classification (best val_acc = 0.788, best val_f1 = 0.761, inférieurs à O3).



9. Étude d’ablation et synthèse des résultats

Le tableau d’ablation confirme trois points : (i) O3 est meilleur en classification (0.789 / 0.800), (ii) O1_C1 et O2 sont les plus cohérents spatialement parmi les variantes standard (IoU 0.580 et 0.461), (iii) O5 renforce l’alignement spatial mais avec un compromis sur la performance de classification.

tag	best_epoch	best_val_acc	best_val_f1	n_val	iou_mean	iou_std
O1_A	2	0.522	0.686	180	0.257	0.154
O1_B	3	0.522	0.686	180	0.230	0.066
O1_C1	3	0.522	0.686	180	0.580	0.106
O1_C2	3	0.522	0.686	180	0.006	0.019
O2	10	0.744	0.770	180	0.461	0.092
O3	5	0.789	0.800	180	0.269	0.120
O5	6	0.788	0.761	180	0.325	0.196

10. Conclusion

Ce projet confirme l’intérêt des architectures CrossViT multi-branches pour la classification d’images botaniques. O3 meilleur en classification; O1_C1 meilleur en IoU; O5 améliore surtout l’alignement de l’attention. Les expériences montrent que la pondération des patches (O3) maximise la performance de classification, tandis que l’intégration explicite d’un terme IoU (O5) améliore surtout l’alignement spatial de l’attention. En pratique, les résultats mettent en évidence un compromis entre performance de classification et interprétabilité spatiale selon l’objectif visé.