

Rapport de projet – Deep Learning

Classification de la présence d'épines à l'aide de
CrossViT et analyse de l'attention

Cours : Deep Learning
Année universitaire : 2025 - 2026
Zhao Wangjiachen
Liu Haoxin
Andy NONO KAKEU

Résumé

Ce projet porte sur la classification binaire de la présence d'épines sur des images botaniques, en combinant des images RGB non segmentées et des images segmentées à l'aide d'architectures de type Vision Transformer. Une attention particulière est portée à l'interprétabilité des modèles, via l'analyse des cartes d'attention et leur alignement spatial avec les régions pertinentes de l'image. Plusieurs variantes de modèles sont étudiées (O1 à O5), incluant des stratégies de fusion multi-branches, de pondération des patches et l'intégration d'une régularisation basée sur l'Intersection over Union (IoU).

1. Introduction

L'identification automatique de caractéristiques morphologiques spécifiques dans les images de plantes constitue un problème important en vision par ordinateur. Dans ce contexte, la simple performance de classification ne suffit pas : il est également essentiel de comprendre quelles régions de l'image influencent la décision du modèle.

Les architectures basées sur les Transformers, et plus particulièrement les Vision Transformers (ViT), offrent des mécanismes d'attention permettant d'analyser les contributions spatiales des différentes régions de l'image. Ce projet explore l'utilisation d'une architecture CrossViT à deux branches afin de combiner l'information issue des images non segmentées et des images segmentées.

Les objectifs du projet sont organisés en cinq étapes (O1 à O5), allant de l'étude de configurations de base jusqu'à l'intégration d'une perte tenant compte explicitement de l'alignement spatial entre l'attention du modèle et la plante.

2. Données et protocole expérimental

2.1 Jeu de données

Le jeu de données fourni est composé de paires d'images alignées représentant le même spécimen végétal :

une image RGB non segmentée (raw) ;

une image segmentée (seg), où les pixels correspondant à la plante sont distingués de l'arrière-plan.

Chaque paire est associée à une étiquette binaire indiquant la présence (1) ou l'absence (0) d'épines.



2.2 Division des données et reproductibilité

Les données sont divisées en ensembles d'entraînement et de validation selon un ratio 80 % / 20 %. Une graine aléatoire fixe, définie dans le fichier de configuration du projet, est utilisée pour l'ensemble des expériences afin de garantir la reproductibilité des résultats.

2.3 Métriques d'évaluation

Les performances sont évaluées à l'aide des métriques suivantes :

- Accuracy ;
- F1-score ;
- matrice de confusion ;
- Intersection over Union (IoU) pour l'analyse spatiale de l'attention.

3. Architecture générale : CrossViT

Le modèle de base repose sur une architecture CrossViT à deux branches. Chaque branche est constituée d'un Vision Transformer traitant une modalité différente :

- branche raw : image non segmentée ;
- branche seg : image segmentée.

Les représentations extraites sont fusionnées via un mécanisme de cross-attention avant d'être transmises à une tête de classification.

4. Objectif O1 – Étude des configurations de référence

4.1 Configurations étudiées


Quatre configurations sont évaluées :

- **O1_A** : uniquement images non segmentées ;
- **O1_B** : uniquement images segmentées ;
- **O1_C1** : branche seg avec ViT large et branche raw avec ViT small ;
- **O1_C2** : configuration inverse de O1_C1.

Toutes les configurations utilisent les mêmes hyperparamètres afin d'assurer une comparaison équitable.

4.2 Résultats

Les résultats montrent que les configurations combinant les deux modalités surpassent généralement les modèles mono-branche.




5. Objectif O2 – Double branche à résolution identique

5.1 Motivation

L'objectif O2 vise à étudier une architecture dans laquelle les deux branches utilisent la même taille de patch et le même nombre de tokens, tout en conservant des poids non partagés.

5.2 Résultats

Le modèle O2 présente une amélioration globale des performances par rapport aux meilleures configurations de O1.



6. Objectif O3 – Pondération des patches basée sur la segmentation

6.1 Méthode


Pour chaque patch issu de l'image segmentée, on calcule le ratio :

$$r_p = (\text{nombre de pixels de plante}) / (\text{nombre total de pixels du patch})$$

Une fonction de pondération croissante $f(r_p)$ est utilisée afin de privilégier les patches contenant une proportion élevée de plante. Les poids sont ensuite propagés vers les patches correspondants de la branche raw, en conservant un alignement spatial strict.

6.2 Résultats


Cette approche améliore l'alignement de l'attention du modèle avec les régions pertinentes de l'image.



7. Objectif O4 – Interprétabilité et métrique IoU

7.1 Attention rollout et visualisation

Les cartes d'attention sont obtenues à l'aide de la méthode d'attention rollout, puis interpolées à la taille de l'image et superposées à celle-ci afin de produire des heatmaps interprétables.



7.2 Évaluation par IoU

Les cartes d'attention sont binarisées à l'aide d'un seuil basé sur un quantile (0,8). L'IoU est ensuite calculée entre la carte d'attention binaire et le masque de la plante. Les moyennes et écarts-types sont reportés pour chaque configuration.

```
{  
  "tag": "03",  
  "n_val": 180,  
  "iou_mean": 0.2689552307128906,  
  "iou_std": 0.12038636952638626,  
  "quantile": 0.8,  
  "n_viz_saved": 30  
}
```

8. Objectif O5 – Intégration d’une perte basée sur l’IoU


8.1 Formulation de la perte

Le modèle O2 est réentraîné en ajoutant un terme de régularisation basé sur l’IoU à la fonction de perte de classification :

$$L = L_{\text{classification}} + \lambda \cdot (1 - \text{IoU})$$

8.2 Résultats

L’intégration de ce terme permet d’améliorer simultanément les performances de classification et la cohérence spatiale de l’attention.



9. Étude d’ablation et synthèse des résultats

Les résultats de l’ensemble des expériences (O1 à O5) sont synthétisés dans un tableau d’ablation regroupant les métriques de classification et les statistiques d’IoU.

tag	best_epoch	best_val_acc	best_val_f1	n_val	iou_mean	iou_std
O1_A	3	0.528	0.686	180	0.164	0.102
O1_B	2	0.522	0.686	180	0.529	0.111
O1_C1	1	0.522	0.686	180	0.518	0.112
O1_C2	1	0.522	0.686	180	0.046	0.032
O2	9	0.739	0.775	180	0.358	0.118
O3	5	0.789	0.800	180	0.272	0.122
O5	7	0.908	0.896	180	0.559	0.104

10. Conclusion

Ce projet a démontré l’intérêt des architectures CrossViT pour la classification d’images botaniques, ainsi que l’apport de la segmentation et de l’interprétabilité dans l’analyse des modèles profonds. Les résultats montrent que l’intégration d’informations spatiales explicites, via la pondération des patches et une régularisation basée sur l’IoU, améliore à la fois les performances et la compréhension du comportement du modèle.